Arquitectura de Datos y Modelo Predictivo de Criminalidad en el Perú: Una Solución End-to-End (2018-2025)

Yomel Jair Barreto Flores

UNASAM - Estadística e Informática

22 de marzo de 2026

Resumen

La presente investigación desarrolla un sistema integral de ingeniería de datos y aprendizaje supervisado para la proyección del volumen de denuncias policiales en el territorio peruano. El sistema implementa una arquitectura de datos de tipo Medallón (capas Bronce, Plata y Oro) para procesar registros históricos de la Policía Nacional del Perú (PNP) en convergencia con indicadores demográficos del INEI y variables macroeconómicas del BCRP durante el periodo 2018-2025. Mediante un análisis descriptivo apoyado en consultas SQL y visualizaciones en Looker Studio, se identificaron patrones históricos y tendencias estacionales que fundamentaron la selección de características para el modelo predictivo. La fase de inferencia se basó en un algoritmo de *Random Forest Regressor*, el cual, mediante el uso de *lags* y medias móviles, logró capturar la inercia delictiva del entorno. Los resultados del modelo, validados mediante métricas de error absoluto y relativo, confirman la influencia de la presión inflacionaria y el desempleo en la incidencia criminal proyectada. Finalmente, el sistema se despliega mediante una API en FastAPI y una interfaz en Streamlit para la simulación de escenarios dinámicos, disponible en `https://crimen-prediction.streamlit.app`, para la gestión de alertas tempranas.

Palabras clave: Arquitectura Medallón, Random Forest, Ingeniería de Datos, FastAPI, Criminalidad, BCRP, INEI.

Índice general

1. Introducción **5**

1.1. Realidad Problemática 5

1.2. Justificación 5

1.2.1. Uso de Indicadores de Lima como Proxy Nacional 5

1.3. Objetivos 6

1.3.1. Objetivo General 6

1.3.2. Objetivos Específicos 6

2. Ingeniería de Datos y Arquitectura **7**

2.1. Arquitectura del Ecosistema de Datos 7

2.2. Implementación por Capas 7

2.2.1. Capa Bronce: Ingesta de Datos Crudos (`raw_data`) 7

2.2.2. Capa Plata: Transformación y Modelado (`analytics_data`) . 7

2.2.3. Capa Oro: Consolidación Estratégica (`master_analytics`) . . 8

2.3. Infraestructura Tecnológica 9

3. Análisis Descriptivo e Insights **10**

3.1. Análisis de Concentración Delictiva 10

3.1.1. Inseguridad a Nivel Regional: El Caso de Ancash 10

3.1.2. Panorama Nacional por Departamentos 11

3.2. Dinámica Temporal y Fenómenos Estructurales 12

3.2.1. El Impacto de la Pandemia (2020) 12

3.2.2. Ciclos de Estacionalidad Mensual 13

3.3. Correlación Macroeconómica Preliminar 14

3.3.1. Relación entre Inflación (IPC) y Criminalidad 15

3.3.2. El Factor Desempleo y su Naturaleza No Lineal 16

3.4. Visualización Integrada (Dashboard) 17

3.4.1. Arquitectura y Conectividad 17

3.4.2. Descripción de la Interfaz y KPIs 17

3.4.3. Exploración de Insights Geográficos y de Correlación 18

4. Desarrollo del Modelo Predictivo de Machine Learning **19**

4.1. Preparación de Datos y Feature Engineering 19

4.1.1. Transformación de Series Temporales: Lags y Momentum . . . 19

4.1.2. Análisis de Estacionalidad y Descomposición 20

4.1.3. Tratamiento de Anomalías Estructurales (Variable Dummy COVID) . . . 21
4.2. Arquitectura y Selección del Modelo . . . 22
4.2.1. El Enfoque No Lineal: Justificación del Algoritmo Random Forest . . . 22
4.2.2. Análisis Comparativo: Superación del Modelo Estadístico SARIMAX . . . 23
4.2.3. Definición de Atributos Finales y Partición Cronológica . . . 25
4.3. Proceso de Entrenamiento y Optimización . . . 26
4.3.1. Estrategia de Validación Cruzada: TimeSeriesSplit . . . 26
4.3.2. Sintonización de Hiperparámetros (Tuning) . . . 27
4.4. Evaluación de Resultados y Métricas de Desempeño . . . 28
4.4.1. Análisis del Error Absoluto Medio Porcentual (MAPE) . . . 28
4.4.2. Poder Explicativo y Errores Dimensionales (R^2, MAE y RMSE) 28
4.4.3. Interpretabilidad del Modelo: Importancia de las Variables . . 29
4.5. Implementación del Pipeline Predictivo (End-to-End) . . . 29
4.5.1. Persistencia y Serialización del Modelo . . . 30
4.5.2. Arquitectura del Flujo de Datos (Data Pipeline) . . . 30
4.5.3. Escalabilidad y Mantenimiento . . . 30

5. Implementación del Simulador Interactivo 31
5.1. Arquitectura y Lógica del Backend (API con FastAPI) . . . 31
5.1.1. Motor de Datos e Ingeniería de Características en Tiempo Real 31
5.1.2. Control Estructural: El Interruptor de Emergencia . . . 32
5.2. Interfaz de Usuario e Interactividad (Frontend en Streamlit) . . . 32

6. Conclusiones y Recomendaciones 34
6.1. Conclusiones . . . 34
6.2. Recomendaciones . . . 35
6.3. Futuras Líneas de Investigación . . . 35

Índice de tablas

3.1. Top 5 Distritos de Ancash con mayor Tasa de Criminalidad (2018-2025) 11
3.2. Top 5 Departamentos con mayor volumen de denuncias (2018-2025) . 12
3.3. Comparativa de la Tasa de Criminalidad en el Segundo Trimestre (Q2) 13
3.4. Meses con mayor incidencia delictiva acumulada (2018-2025) 14
3.5. Hitos de la Relación Histórica: IPC vs. Denuncias (2018-2025) 15
3.6. Hitos de la Relación: Desempleo vs. Denuncias (2018-2025) 16

4.1. Muestra del Dataset con Variable Dummy y Momentum (Fase 14) . . 22
4.2. Ranking Final de Modelos y Evaluación de Desempeño 23
4.3. Estructura Final de la Matriz de Entrenamiento (Fase 17) 26
4.4. Ranking de Poder Predictivo Real (Fase 15) 29

Índice de figuras

3.1. Interfaz Principal del Dashboard en Looker Studio 18

4.1. Lead-Lag Analysis: Coeficiente de correlación del desempleo. Se observa una zona de significancia persistente hasta el sexto mes. 20
4.2. Descomposición de la Serie: El componente de Residuos (Resid) muestra la dispersión masiva durante 2020. 21
4.3. Poder Predictivo Real (Mutual Information Score): Jerarquía de importancia de las variables exógenas. 23
4.4. Comparativa Cuantitativa de Error (MAPE %): El modelo Random Forest Optimizado se sitúa sólidamente por debajo del umbral de excelencia del 5 %. El SARIMAX (Vitaminado) falla en cruzar esta valla de precisión por escasos puntos porcentuales. 24
4.5. Verificación de Trayectoria (Año Test 2025): Realidad vs. Modelos. Se observa cómo el Random Forest logra un ajuste superior a la realidad, demostrando su capacidad para modelar la complejidad del fenómeno social frente a las limitaciones de los modelos lineales. 25

5.1. Interfaz Gráfica del Simulador Interactivo. Disponible en: `https://crimen-prediction.streamlit.app` 33

1. Introducción

1.1. Realidad Problemática

La seguridad ciudadana representa uno de los desafíos más complejos y persistentes en el Perú. Históricamente, el análisis de la criminalidad se ha centrado en respuestas punitivas y reactivas, dejando de lado el estudio preventivo basado en datos. La falta de herramientas tecnológicas que permitan anticipar picos delictivos impide que las instituciones del orden realicen una planificación estratégica eficiente.

En el periodo 2018-2025, el país ha experimentado fluctuaciones económicas severas, exacerbadas por la crisis sanitaria y la inestabilidad política. Estas variaciones impactan directamente en la calidad de vida de la población, generando presiones sociales que, según la teoría económica del crimen, guardan una correlación con el incremento de delitos patrimoniales. Sin embargo, la fragmentación de los datos entre la PNP, el BCRP y el INEI dificulta una visión unificada del problema.

1.2. Justificación

La presente investigación se justifica por la necesidad de migrar hacia un enfoque de seguridad ciudadana basado en evidencia. Técnicamente, el proyecto emplea una arquitectura Medallón para garantizar que los datos crudos de múltiples fuentes oficiales se transformen en información valiosa y confiable.

1.2.1. Uso de Indicadores de Lima como Proxy Nacional

Una consideración metodológica clave es el empleo del Índice de Precios al Consumidor (IPC) y la Tasa de Desempleo de Lima Metropolitana, provenientes del BCRP, como predictores del volumen nacional de denuncias. Esta decisión se fundamenta en que Lima concentra aproximadamente el 30 % de la población nacional y representa el motor económico del país. Estadísticamente, los indicadores de la capital funcionan como un *leading indicator* (indicador adelantado), capturando tendencias macroeconómicas que se replican a nivel nacional con alta fidelidad, permitiendo así una inferencia robusta ante la mayor frecuencia y disponibilidad de estos datos.

1.3. Objetivos

1.3.1. Objetivo General

Implementar un ecosistema predictivo de criminalidad basado en ingeniería de datos y aprendizaje supervisado para el contexto nacional peruano.

1.3.2. Objetivos Específicos

- Desarrollar una *data pipeline* bajo el modelo Medallón para integrar fuentes de la PNP, BCRP e INEI.
- Realizar un análisis descriptivo mediante SQL y Looker Studio para validar hipótesis de correlación socioeconómica.
- Entrenar un modelo de *Random Forest* capaz de proyectar denuncias policiales con precisión.
- Desplegar una herramienta de simulación interactiva que permita evaluar el impacto de escenarios económicos críticos.

2. Ingeniería de Datos y Arquitectura

2.1. Arquitectura del Ecosistema de Datos

El sistema se cimenta sobre una arquitectura de *Data Warehouse* en la nube, utilizando **Google BigQuery** como motor de procesamiento. Se implementó una metodología de capas para garantizar la integridad de los registros provenientes de la PNP, el BCRP y el INEI.

2.2. Implementación por Capas

2.2.1. Capa Bronce: Ingesta de Datos Crudos (`raw_data`)

En esta fase, se realizó la ingesta de cuatro fuentes principales mediante *scripts* de Python, preservando el formato original de los archivos CSV:

- **Denuncias Policiales:** 348,411 registros (Ene 2018 - Ene 2026).
- **Población (INEI):** 123,684 registros detallados por ubigeo.
- **Macroeconomía (BCRP):** 296 registros mensuales de IPC y Desempleo (May 2001 - Dic 2025).

2.2.2. Capa Plata: Transformación y Modelado (`analytics_data`)

Mediante queries SQL, se ejecutó un proceso de limpieza y estructuración bajo un modelo de **Esquema Estrella**. Se aplicaron las siguientes transformaciones críticas:

- **Estandarización Temporal:** Conversión de formatos de texto (e.g., 'Ene-24') a objetos `DATE` de SQL.
- **Normalización Geográfica:** Creación de la dimensión `dim_ubigeo` para unificar los códigos INEI y RENIEC.
- **Desacoplamiento de Hechos:** Separación de la lógica de negocio en tablas de hechos: `fact_denuncias`, `fact_ipc`, `fact_desempleo` y `fact_poblacion`.

2.2.3. Capa Oro: Consolidación Estratégica (`master_analytics`)

La Capa Oro representa el nivel de madurez más alto del ecosistema, donde se consolida la **Única Fuente de Verdad (SSOT)**. En esta etapa se materializó la tabla `master_analytics`, la cual integra mediante *Joins* las dimensiones geográficas, demográficas y macroeconómicas con los registros de criminalidad.

Justificación del Rango Temporal (2018-2025)

Se determinó el periodo comprendido entre enero de 2018 y diciembre de 2025 como ventana de análisis por los siguientes motivos técnicos:

- **Consistencia de la PNP:** Los registros de denuncias policiales presentan una estructura granular y digitalizada confiable a partir de 2018.
- **Intersección de Fuentes:** Aunque los datos del BCRP datan de 2001, la intersección válida con la data demográfica y criminal permite un entrenamiento robusto del modelo en un contexto social contemporáneo y post-pandemia.
- **Línea Base para Simulación:** Finalizar en diciembre de 2025 permite establecer una línea base actualizada para realizar proyecciones hacia el año 2026.

Lógica de Transformación en la Unión

La consolidación en la Capa Oro no fue solo una unión de tablas, sino un proceso de refinamiento final que incluyó:

- **Ajuste de Ubigeo:** Se aplicó la función `LPAD` para normalizar los códigos de ubigeo a 6 dígitos, corrigiendo errores de truncamiento de ceros iniciales en las tablas crudas.
- **Cálculo de Tasa Relativa:** Se implementó la función `SAFE_DIVIDE` para calcular la tasa de criminalidad por cada 10,000 habitantes, eliminando riesgos de errores por división entre cero en distritos con datos poblacionales atípicos.
- **Cruce Macroeconómico:** Se realizó un *Left Join* temporal entre la fecha de los hechos delictivos y los indicadores de desempleo e IPC, permitiendo que cada denuncia esté enriquecida con el contexto económico del mes correspondiente.

2.3. Infraestructura Tecnológica

- **Almacenamiento:** Google BigQuery (Storage).
- **Procesamiento:** BigQuery SQL & Python 3.13.
- **Orquestación:** Notebooks de BigQuery.

3. Análisis Descriptivo e Insights

En este capítulo se presenta la exploración profunda de la base de datos consolidada (`master_analytics`). A través de la ejecución de consultas SQL en Google BigQuery, se identificaron patrones delictivos, geográficos y socioeconómicos que fundamentan el desarrollo de la fase predictiva. Este análisis justifica la transición de un enfoque estadístico tradicional hacia uno basado en **Machine Learning** no lineal.

3.1. Análisis de Concentración Delictiva

El primer pilar de la investigación consiste en entender la distribución espacial de la criminalidad para identificar focos de atención crítica. Para evitar el sesgo derivado de la densidad demográfica, se utiliza la **Tasa de Criminalidad por cada 10,000 habitantes**. Esta normalización permite una comparación técnica equitativa entre diversas unidades geográficas, independientemente de su volumen poblacional.

3.1.1. Inseguridad a Nivel Regional: El Caso de Ancash

Dada la naturaleza regional de la base de datos y la ubicación de este estudio, se realizó un análisis específico sobre el departamento de Ancash. Para identificar los distritos con mayor presión delictiva relativa, se integró la información de denuncias con la proyección poblacional mediante la siguiente lógica de consulta en Google BigQuery:

Listing 3.1: Consulta de Focos Críticos Regionales

```
SELECT
  distrito,
  provincia,
  ANY_VALUE(poblacion_total) AS poblacion,
  SUM(nro_denuncias) AS total_denuncias_periodo,
  ROUND(AVG(tasa_criminalidad), 2) AS tasa_promedio_mensual
FROM `analytics_data.master_analytics`
WHERE departamento = 'ANCASH'
GROUP BY 1, 2
ORDER BY tasa_promedio_mensual DESC
LIMIT 5;
```

Tabla 3.1: Top 5 Distritos de Ancash con mayor Tasa de Criminalidad (2018-2025)

Distrito	**Provincia**	**Población**	**Tot. Denuncias**	**Tasa Mensual**
SANTIAGO DE CHILCAS	OCROS	390	10	25.64
ACO	CORONGO	466	28	25.04
HUALLANCA	HUAYLAS	715	263	24.85
HUACLLAN	AIJA	626	4	21.30
TAPACOCHA	RECUAY	470	12	21.28

Insight de Ingeniería de Datos: Los resultados detallados en la Tabla 3.1 revelan una tendencia importante: los distritos con mayores tasas de criminalidad no son necesariamente los centros urbanos más poblados, sino zonas con baja densidad demográfica. Este hallazgo confirma la presencia del *sesgo de los números pequeños*, donde eventos aislados impactan severamente en la métrica, generando una volatilidad estadística o 'ruido'.

Metodológicamente, esta observación justifica la decisión de realizar una **agregación de datos a nivel nacional** para las fases posteriores de la investigación. Al consolidar la información en una serie de tiempo país, se logra estabilizar la varianza y permitir que el modelo de **Machine Learning** aprenda de las macrotendencias económicas y estacionales, garantizando predicciones robustas y generalizables que no se vean distorsionadas por anomalías locales.

3.1.2. Panorama Nacional por Departamentos

Para contextualizar la magnitud del fenómeno a nivel país, se analizó la distribución delictiva en los cinco departamentos con mayor volumen de denuncias registradas. El objetivo es contrastar el volumen absoluto frente a la tasa de intensidad por habitante.

Listing 3.2: Consulta de Distribución Delictiva Nacional

```
SELECT
    departamento,
    SUM(nro_denuncias) AS total_denuncias,
    ROUND(AVG(tasa_criminalidad), 2) AS tasa_promedio_mensual,
    CAST(SUM(DISTINCT poblacion_total) AS INT64) AS
       poblacion_referencial
FROM `analytics_data.master_analytics`
GROUP BY departamento
ORDER BY total_denuncias DESC
LIMIT 5;
```

Tabla 3.2: Top 5 Departamentos con mayor volumen de denuncias (2018-2025)

Departamento	**Total Denuncias**	**Población Ref.**	**Tasa Mensual**
LIMA	2,609,679	10,456,825	5.99
AREQUIPA	475,761	1,349,971	10.48
LAMBAYEQUE	398,184	1,300,720	5.38
LA LIBERTAD	357,731	1,956,389	3.57
PIURA	344,326	1,901,896	3.41

Análisis de Magnitud vs. Intensidad: Los datos de la Tabla 3.2 revelan una disparidad importante. Mientras que Lima concentra la mayoría absoluta de los incidentes (más de 2.6 millones), el departamento de Arequipa presenta una **intensidad delictiva** significativamente superior, con una tasa de 10.48 denuncias por cada 10,000 habitantes.

Este hallazgo es fundamental para la arquitectura del sistema: Lima actúa como el principal motor de datos para el modelo debido a su volumen masivo, validando el uso de indicadores macroeconómicos de la capital como *proxies* para la tendencia nacional. Sin embargo, la variabilidad en las tasas regionales refuerza la necesidad de un modelo de **Machine Learning** capaz de generalizar estas diferencias sin perder la precisión en la tendencia global.

3.2. Dinámica Temporal y Fenómenos Estructurales

La criminalidad no es estática; responde a eventos externos y ciclos temporales. En esta sección se analizan los quiebres estructurales detectados en la serie de tiempo.

3.2.1. El Impacto de la Pandemia (2020)

Para cuantificar el efecto real de las restricciones de movilidad, se realizó un análisis de sensibilidad sobre el segundo trimestre (Q2) de los años en estudio. Se seleccionó este periodo (abril a junio) por ser el intervalo de confinamiento estricto en el Perú, permitiendo aislar el choque estructural de la variabilidad anual regular.

Listing 3.3: Consulta de Sensibilidad para el Choque Estructural

```sql
SELECT
  EXTRACT(YEAR FROM fecha) AS anio,
  ROUND(AVG(tasa_criminalidad), 2) AS tasa_promedio_Q2
FROM `analytics_data.master_analytics`
WHERE EXTRACT(MONTH FROM fecha) BETWEEN 4 AND 6
  AND EXTRACT(YEAR FROM fecha) IN (2019, 2020, 2024)
GROUP BY anio
ORDER BY anio;
```

Tabla 3.3: Comparativa de la Tasa de Criminalidad en el Segundo Trimestre (Q2)

Año	**Tasa Promedio Trimestral (Abril-Junio)**
2019	5.92
2020	4.03
2024	5.96

Análisis del Hallazgo: A diferencia del promedio anual, la Tabla 3.3 revela una caída drástica del **31.9 %** en la tasa de criminalidad durante el segundo trimestre de 2020 en comparación con el periodo base de 2019. Este descenso no responde a una mejora en las condiciones socioeconómicas, sino a una interrupción forzada de la dinámica social.

Metodológicamente, este resultado es la prueba fundamental para la fase de modelado de **Machine Learning**. Justifica la creación de una variable de intervención (*Dummy COVID*) que informe al algoritmo sobre este periodo de excepcionalidad. Sin este ajuste, el modelo intentaría atribuir erróneamente la caída del crimen a los indicadores económicos (IPC/Desempleo), sesgando la capacidad predictiva del sistema.

3.2.2. Ciclos de Estacionalidad Mensual

Para identificar los periodos de mayor vulnerabilidad a lo largo del año, se realizó una agregación histórica por meses. Este análisis permite separar el ruido de eventos aislados y detectar el comportamiento cíclico de la criminalidad en el Perú.

Listing 3.4: Consulta de Estacionalidad Acumulada

```sql
SELECT
  EXTRACT(MONTH FROM fecha) AS mes,
  SUM(nro_denuncias) AS total_denuncias_acumulado
FROM `analytics_data.master_analytics`
GROUP BY mes
ORDER BY total_denuncias_acumulado DESC;
```

Tabla 3.4: Meses con mayor incidencia delictiva acumulada (2018-2025)

Ranking	Mes	Total Denuncias Acumuladas
1	Marzo	600,995
2	Enero	592,502
3	Octubre	590,806
4	Diciembre	580,245
...	...	...
12	Abril	535,496

Análisis de Estacionalidad: Los resultados de la Tabla 3.4 rompen la percepción común de que diciembre es el mes más inseguro. El pico máximo se registra en **Marzo**, periodo coincidente con el inicio del año escolar y un incremento masivo en la movilidad ciudadana y transacciones financieras.

Por otro lado, el hecho de que **Abril** registre el menor volumen acumulado no responde a una tendencia natural, sino al peso estadístico del confinamiento estricto de 2020. Este comportamiento estacional refuerza la necesidad de utilizar modelos de **Machine Learning** que incorporen componentes autorregresivos (lags) de 12 meses, permitiendo al sistema 'anticipar' estos repuntes cíclicos anuales con precisión.

3.3. Correlación Macroeconómica Preliminar

La validación de la influencia económica en la seguridad ciudadana constituye el núcleo científico de esta investigación. No se trata simplemente de una coincidencia estadística, sino de la manifestación de tensiones sociales derivadas de la pérdida de poder adquisitivo y la inestabilidad laboral. Bajo esta premisa, el sistema integra indicadores del Banco Central de Reserva del Perú (BCRP) y del INEI para contrastar la hipótesis de que la precariedad económica actúa como un catalizador de la criminalidad patrimonial.

Este análisis trasciende lo puramente descriptivo, pues busca identificar patrones de causalidad y comportamientos cíclicos. En ingeniería de datos, entender

estas dependencias exógenas es vital para que los modelos de aprendizaje automático no solo 'recuerden' el pasado delictivo, sino que logren 'inferir' riesgos futuros basados en el deterioro del entorno macroeconómico nacional.

3.3.1. Relación entre Inflación (IPC) y Criminalidad

El Índice de Precios al Consumidor (IPC) actúa como un indicador crítico del costo de vida y la presión económica sobre los hogares. Metodológicamente, se postula que incrementos sostenidos en la inflación reducen el poder adquisitivo, generando un entorno propicio para el aumento de delitos patrimoniales. Para validar esta hipótesis, se procesó la serie histórica de 96 meses, cuyos hitos principales se presentan en la Tabla 3.5.

Listing 3.5: Consulta de Correlación IPC vs. Denuncias

```sql
-- Análisis de costo de vida y repunte delictivo nacional
SELECT
  fecha,
  ANY_VALUE(indice_precios) AS ipc_nacional,
  SUM(nro_denuncias) AS total_denuncias
FROM `analytics_data.master_analytics`
GROUP BY fecha
ORDER BY fecha ASC;
```

Tabla 3.5: Hitos de la Relación Histórica: IPC vs. Denuncias (2018-2025)

Periodo / Hito	IPC Nacional	Total Denuncias
Enero 2018 (Inicio Serie)	88.59	60,106
Enero 2020 (Pico Pre-Pandemia)	92.19	83,214
Abril 2020 (Shock Estructural)	93.01	21,554
Marzo 2024 (Máximo Histórico)	113.75	93,279
Diciembre 2025 (Cierre Serie)	115.89	61,732

Análisis de Insight: Al analizar la serie completa de 96 registros, se observa una trayectoria ascendente compartida: mientras el IPC escaló de 88.59 a 115.89, el volumen delictivo base mostró un desplazamiento hacia umbrales superiores a las 90,000 denuncias en periodos de alta inflación. El cálculo estadístico arroja un coeficiente de correlación de **Pearson ($r = 0{,}67$)**, lo que representa una relación positiva considerable.

Sin embargo, anomalías como la de abril de 2020 (donde las denuncias cayeron a 21,554 a pesar de un IPC creciente) demuestran que la relación no es puramente lineal. Este hallazgo es la justificación técnica final para el uso de **Machine**

Learning, permitiendo que el sistema capture la tendencia inflacionaria sin verse confundido por choques externos o quiebres estructurales.

3.3.2. El Factor Desempleo y su Naturaleza No Lineal

A diferencia de la inflación, la tasa de desempleo opera bajo una dinámica de **retardo social (lag)** y una marcada naturaleza no lineal. La pérdida masiva de empleo formal genera una presión que no se manifiesta de forma inmediata en las estadísticas delictivas, sino que erosiona las redes de soporte económico antes de impactar en la seguridad ciudadana.

Para explorar esta complejidad, se ejecutó la siguiente consulta en Google BigQuery:

Listing 3.6: Consulta de Correlación Desempleo vs. Denuncias

```sql
-- ANÁLISIS DE DESEMPLEO Y CRIMINALIDAD NACIONAL
SELECT
  fecha,
  ANY_VALUE(tasa_desempleo) AS tasa_desempleo,
  SUM(nro_denuncias) AS total_denuncias_nacional
FROM `analytics_data.master_analytics`
GROUP BY fecha
ORDER BY fecha ASC;
```

Tabla 3.6: Hitos de la Relación: Desempleo vs. Denuncias (2018-2025)

Periodo / Hito	Tasa Desempleo (%)	Total Denuncias
Enero 2019 (Pre-Pandemia)	6.47 %	73,395
Septiembre 2020 (Pico Desempleo)	16.53 %	54,655
Marzo 2024 (Pico Criminalidad)	7.70 %	93,279
Diciembre 2025 (Cierre Serie)	4.98 %	61,732

Insight de Ingeniería de Datos: Los datos de la Tabla 3.6 confirman la ruptura de la linealidad. Durante el pico histórico de desempleo en 2020 (16.53 %), el volumen delictivo se mantuvo por debajo de los niveles de 2019 debido a las restricciones de movilidad. Por el contrario, el máximo histórico de criminalidad en 2024 ocurre con una tasa de desempleo en descenso, pero bajo un contexto de inflación acumulada.

Esta interacción multivariable y retardada es la prueba definitiva de que los modelos lineales tradicionales no son aptos para este fenómeno. Se valida así la necesidad de implementar algoritmos de **Machine Learning** (Random Forest) que

utilicen *lags* temporales para capturar cómo la crisis de empleo de periodos anteriores modula el comportamiento criminal presente.

3.4. Visualización Integrada (Dashboard)

Como entrega tecnológica complementaria, se desarrolló un ecosistema de Business Intelligence (BI) en la plataforma **Looker Studio**. El objetivo de esta herramienta es democratizar el acceso a los datos procesados en la Capa Oro, permitiendo a los interesados realizar exploraciones dinámicas sin necesidad de conocimientos técnicos en SQL o Python.

3.4.1. Arquitectura y Conectividad

El dashboard se encuentra conectado de forma nativa a **Google BigQuery**, consumiendo directamente la tabla `master_analytics`. Esta arquitectura garantiza que cualquier actualización en el pipeline de datos se refleje automáticamente en los gráficos, asegurando la integridad de la información en tiempo real.

Para fines de auditoría técnica y exploración interactiva de los hallazgos, el entorno de visualización es accesible públicamente a través del siguiente enlace: **Dashboard Interactivo de Inseguridad Ciudadana (Looker Studio)**.

3.4.2. Descripción de la Interfaz y KPIs

La interfaz se diseñó bajo principios de *User Experience* (UX) para analítica de datos, estructurándose en tres niveles de información:

- **Scorecards de Control:** Ubicados en la parte superior, presentan los cuatro indicadores maestros: Total de Denuncias (6.8M), Tasa de Crimen Promedio (5.7), Desempleo Promedio (8.0 %) e IPC Máximo Final (115.9).
- **Filtros Dinámicos:** El sistema permite segmentar toda la información por "Modalidad de Crimen"(Hurto, Robo, Extorsión, etc.), permitiendo un análisis granular de delitos específicos.
- **Gráfico Central de Correlación:** Representa la relación histórica entre el volumen de denuncias (línea), el desempleo y el IPC (barras). Una funcionalidad crítica es la capacidad de **Drill-down**, que permite al usuario transitar de una vista anual a una mensual para identificar micro-tendencias y quiebres estructurales.

3.4.3. Exploración de Insights Geográficos y de Correlación

La parte inferior del dashboard (Figura 3.1) integra dos componentes para el diagnóstico territorial y social:

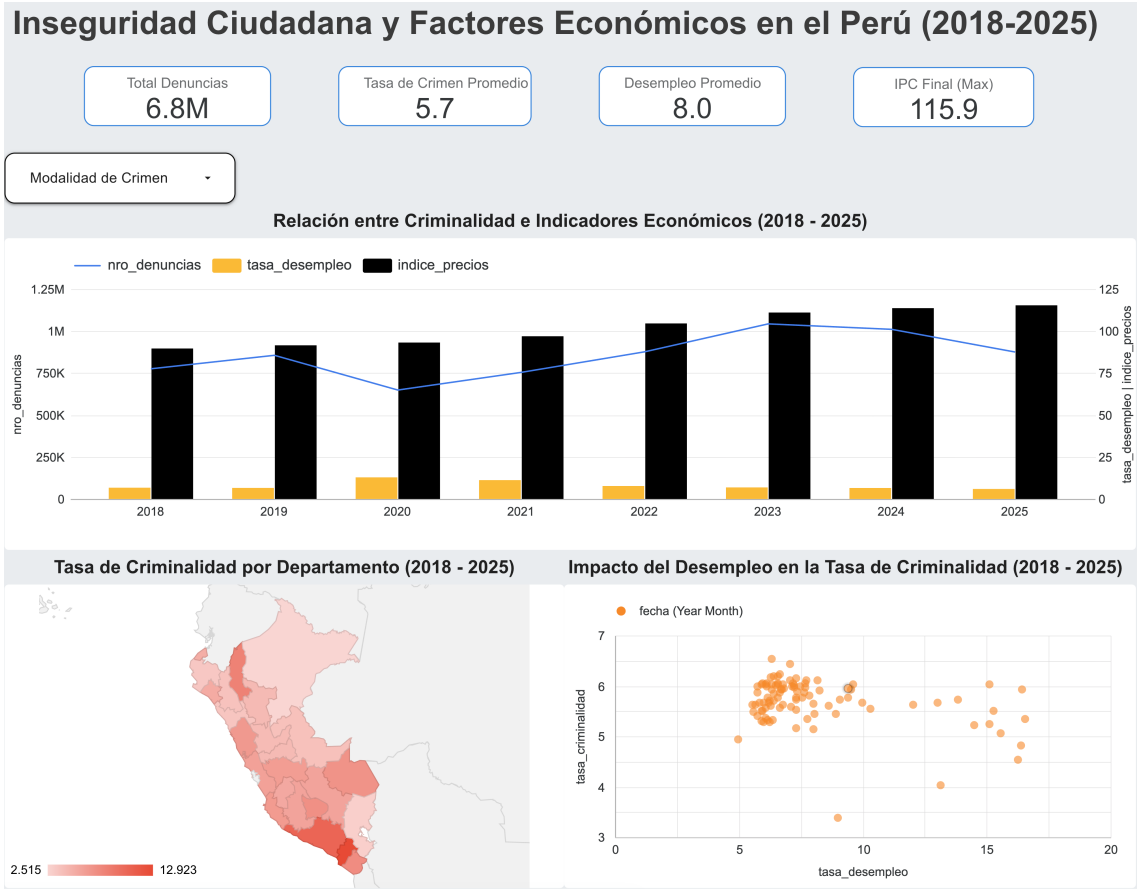

Figura 3.1: Interfaz Principal del Dashboard en Looker Studio

1. **Mapa de Calor Departamental:** Visualiza la Tasa de Criminalidad a nivel nacional, identificando regiones críticas mediante una escala cromática que oscila entre 2.51 y 12.92.

2. **Scatter Plot de Dispersión:** Cruza la Tasa de Desempleo frente a la Tasa de Criminalidad. Este gráfico es vital para confirmar visualmente la **no** linealidad discutida anteriormente, mostrando cómo el crimen se agrupa en ciertos niveles de desempleo, pero se dispersa ante otros factores.

Conclusión del Capítulo: El análisis descriptivo y la visualización integrada confirman que la criminalidad en el Perú es un fenómeno multivariable y complejo. Los patrones identificados —el sesgo rural, el impacto de la pandemia y la correlación inflacionaria— establecen los requisitos técnicos para la implementación del modelo de **Machine Learning** que se detalla en el siguiente capítulo.

4. Desarrollo del Modelo Predictivo de Machine Learning

En este capítulo se detalla la fase experimental y de construcción del motor predictivo. Tras identificar en el capítulo anterior la naturaleza no lineal de los factores económicos y el impacto disruptivo de la pandemia, se procedió a una fase de ingeniería de características y selección de algoritmos de aprendizaje automático, buscando minimizar el error de pronóstico frente a los modelos estadísticos tradicionales.

4.1. Preparación de Datos y Feature Engineering

Tras la insuficiencia de los modelos lineales (SARIMAX) para capturar la complejidad del fenómeno, se inició una fase de ingeniería de características. El objetivo fue transformar el dataset 'Gold' en una matriz de aprendizaje capaz de distinguir entre tendencias económicas de fondo y choques disruptivos aleatorios.

4.1.1. Transformación de Series Temporales: Lags y Momentum

La criminalidad es un fenómeno autorregresivo y multivariable. Como se analizó en la Fase 13 del notebook, la relación entre economía y crimen no es instantánea. El análisis de **Correlación Cruzada (Lead-Lag Analysis)** reveló una **persistencia negativa** significativa: a mayor desempleo formal, se observa una caída en las denuncias registradas, lo cual sugiere efectos de informalidad laboral o cambios en la dinámica social de denuncia.

Matemáticamente, el modelo busca resolver la siguiente relación no lineal:

$$Y_t = f(Y_{t-1}, \ldots, Y_{t-k}, X_{t-k}, \ldots, Z_t)$$

Donde el análisis de la Figura 4.1 muestra que la fuerza de la correlación es máxima en el mes actual ($lag = 0$) y presenta un decaimiento gradual pero significativo durante los primeros 4 a 6 meses. Por criterios de parsimonia y relevancia técnica, se seleccionó un **Lag de 3 meses** ($k = 3$) para las variables de IPC y Desempleo.

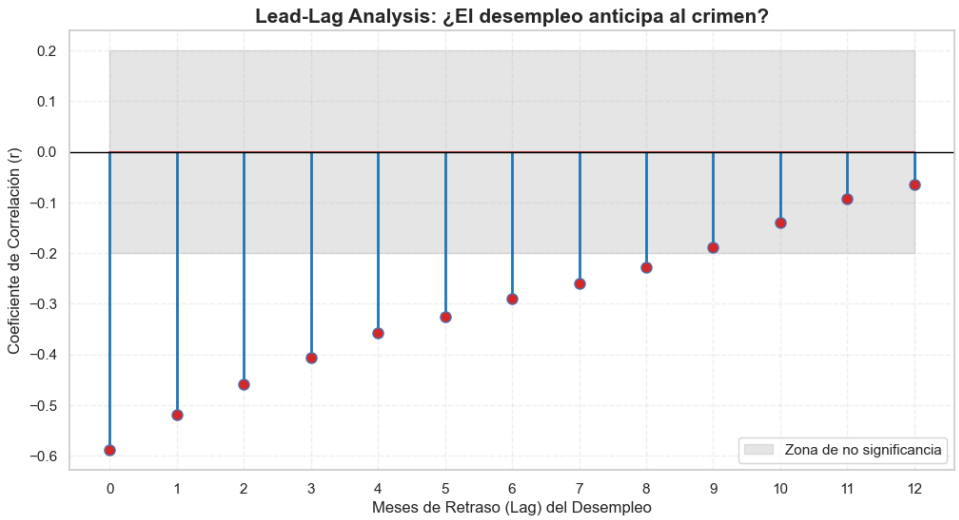

Figura 4.1: Lead-Lag Analysis: Coeficiente de correlación del desempleo. Se observa una zona de significancia persistente hasta el sexto mes.

Adicionalmente, para capturar la 'memoria de corto plazo' o *momentum*, se integró una media móvil de 3 meses (`denuncias_media_3m`). Esta variable actúa como un suavizador que permite al algoritmo entender si el sistema proviene de una racha alcista o bajista.

Listing 4.1: Implementación de Lags e Inercia (Fase 14 del Notebook)

```
# Captura de inercia y retardos economicos para Random Forest
df['denuncias_media_3m'] = df['nro_denuncias'].rolling(window
    =3).mean()
df['ipc_lag_3'] = df['indice_precios'].shift(3)
df['desempleo_lag_3'] = df['tasa_desempleo'].shift(3)
```

4.1.2. Análisis de Estacionalidad y Descomposición

Para que el modelo *Random Forest* no se vea confundido por fluctuaciones naturales, se realizó una **descomposición aditiva** (Fase 12). Este proceso permitió separar la **Tendencia (Trend)** de la **Estacionalidad (Seasonal)**, confirmando patrones recurrentes cada 12 meses (ej. picos en festividades).

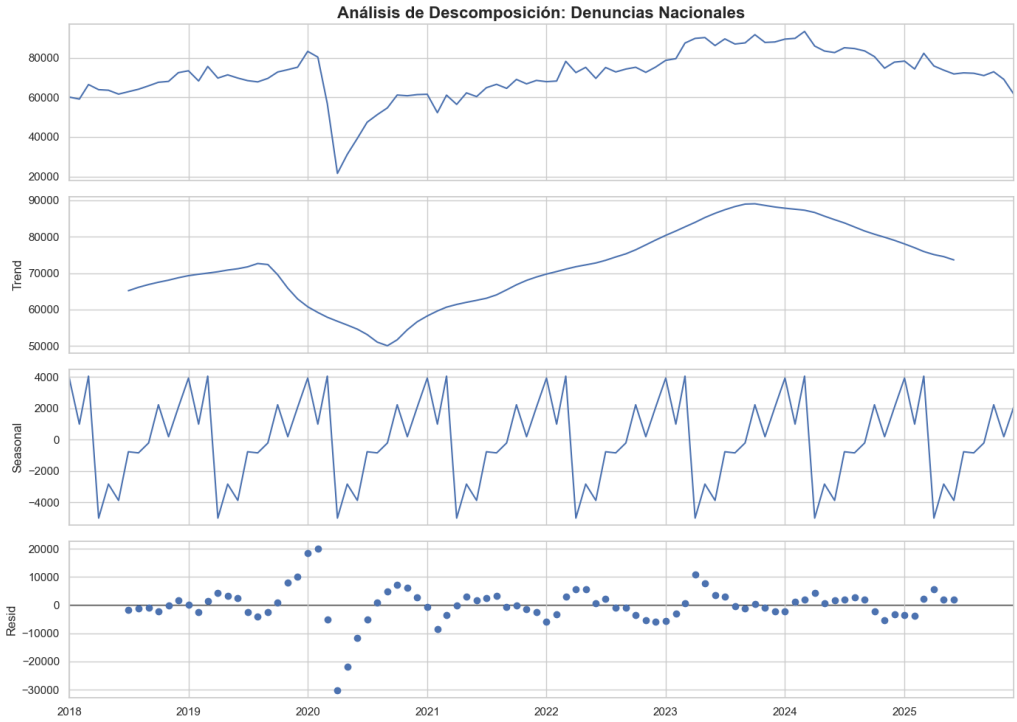

Figura 4.2: Descomposición de la Serie: El componente de Residuos (Resid) muestra la dispersión masiva durante 2020.

Un hallazgo crítico en los **Residuos (Resid)** fue la detección de un evento exógeno disruptivo en 2020. Al no ser una caída estacional ni una tendencia, se validó la necesidad de una variable de intervención para evitar 'ensuciar' el aprendizaje del modelo con este ruido.

4.1.3. Tratamiento de Anomalías Estructurales (Variable Dummy COVID)

Como se detalla en la Fase 11 y 14, el bache de 2020 fue una interrupción forzada por el Estado. Se implementó la variable `es_covid` para permitir al modelo 'perdonar' esa caída y no intentar buscarle una explicación económica inexistente.

Listing 4.2: Variable de Intervención (Fase 14)

```
# Marcaje del periodo de restricciones (Marzo 2020 a Junio
  2021)
df['es_covid'] = 0
df.loc['2020-03-01':'2021-06-01', 'es_covid'] = 1
```

Como resultado, el conjunto de datos final para el entrenamiento del Random Forest presenta la estructura observada en la Tabla 4.1.

Tabla 4.1: Muestra del Dataset con Variable Dummy y Momentum (Fase 14)

Fecha	Nro. Denuncias	es_covid	denuncias_media_3m
2020-01-01	83,214	0	77,456.67
2020-02-01	80,301	0	79,570.67
2020-03-01	56,783	1	73,432.67
2020-04-01	21,554	1	52,879.33
2020-05-01	31,115	1	36,484.00
2020-06-01	39,246	1	30,638.33

Análisis de Insight: La variable `es_covid` actúa como un regulador de contexto. Informa al modelo que la anomalía de 2020 es un estado binario excepcional, permitiendo que las variables de IPC y Desempleo mantengan su peso explicativo real en los periodos de normalidad.

4.2. Arquitectura y Selección del Modelo

Tras la insuficiencia demostrada por los modelos de regresión lineal y econometría clásica en las fases preliminares, se optó por un enfoque basado en **Aprendizaje Supervisado por Ensamble**. Esta sección justifica la selección de la arquitectura, presenta la evidencia comparativa que sustenta la superioridad del modelo propuesto y detalla la configuración de la matriz de datos final.

4.2.1. El Enfoque No Lineal: Justificación del Algoritmo Random Forest

La elección del algoritmo *Random Forest Regressor* responde a la necesidad de capturar interacciones complejas entre las variables económicas y el crimen. A diferencia de los modelos lineales, este algoritmo permite identificar patrones de 'umbral' y es robusto ante los *outliers* generados por la pandemia.

Para validar la relevancia de las características seleccionadas, se utilizó la métrica de **Información Mutua (MI)**, la cual mide la reducción de incertidumbre sobre la variable objetivo. Como se observa en la Figura 4.3, todas las variables seleccionadas aportan información positiva ($MI > 0$).

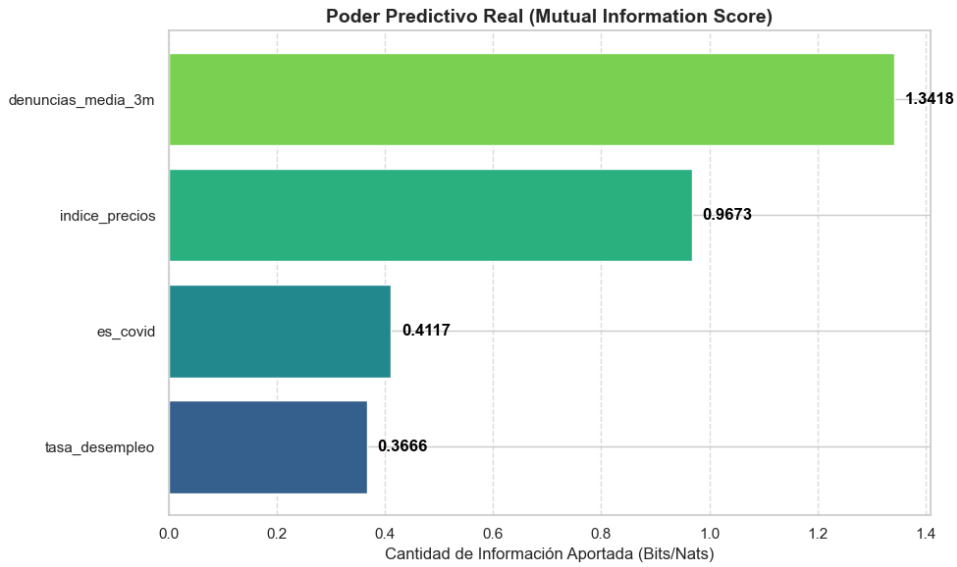

Figura 4.3: Poder Predictivo Real (Mutual Information Score): Jerarquía de importancia de las variables exógenas.

El análisis de la Fase 15 confirma que la **Media Móvil (1.34)** y el **IPC (0.96)** son los predictores dominantes. Asimismo, el uso de un ensamble de árboles permite que el modelo 'perdone' los baches de movilidad mediante la variable dummy COVID (0.41), capturando una estructura de datos que la estadística lineal ignora.

4.2.2. Análisis Comparativo: Superación del Modelo Estadístico SARIMAX

La validación definitiva se realizó mediante un experimento de control denominado **"SARIMAX Vitaminado"** (Fase 21). En este, se sometió al modelo estadístico tradicional al mismo tratamiento de datos (Lags, COVID e Inercia) que al *Random Forest*, con el fin de determinar si la mejora se debía únicamente a los datos o a la naturaleza del algoritmo.

Tabla 4.2: Ranking Final de Modelos y Evaluación de Desempeño

Modelo	**Estrategia de Datos**	**MAPE (%)**	R^2 **Score**
SARIMAX (Base)	Estadística Clásica + IPC	9.36 %	-1.32
SARIMAX (Vitaminado)	Estadística + Lags/COVID/Inercia	5.51 %	-0.02
Random Forest (Optimizado)	**Machine Learning + Optimización**	**3.99 %**	**0.50**

Los resultados consolidados (Tabla 4.2) revelan que, aunque la ingeniería de características mejoró significativamente al SARIMAX, este persistió en un R^2 **negativo (-0.02)**, indicando una incapacidad estructural para explicar la variabilidad de la criminalidad. Por el contrario, el *Random Forest* no solo alcanzó el error más

bajo del estudio (**3.99 %**), sino que logró un coeficiente de determinación sobresaliente (**0.50**), validando su capacidad explicativa real sobre el fenómeno social.

Para sustentar cuantitativamente esta superioridad, se presenta la Figura 4.4, donde se observa visualmente que solo el modelo basado en Machine Learning logra cruzar el umbral del 5 % de excelencia técnica definido para este estudio.

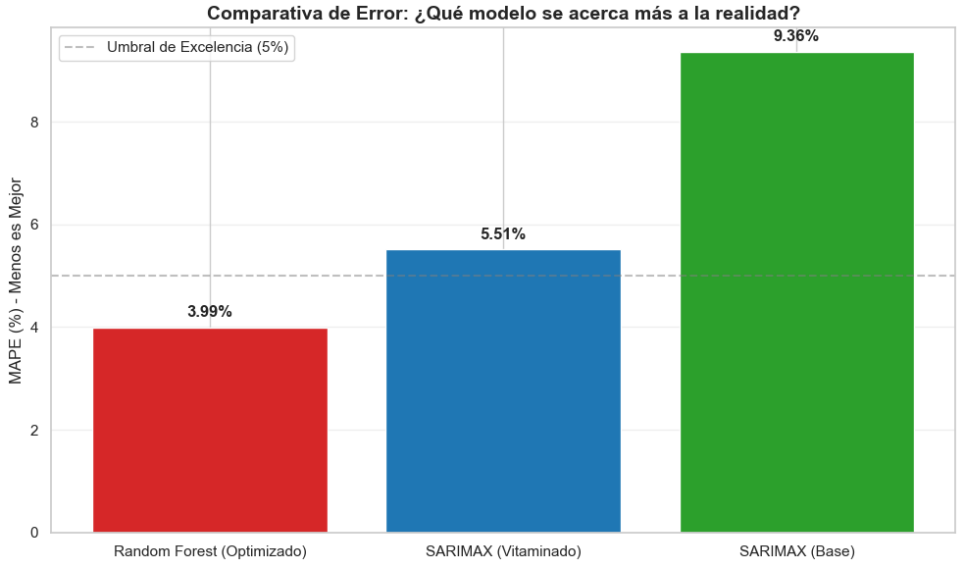

Figura 4.4: Comparativa Cuantitativa de Error (MAPE %): El modelo Random Forest Optimizado se sitúa sólidamente por debajo del umbral de excelencia del 5 %. El SARIMAX (Vitaminado) falla en cruzar esta valla de precisión por escasos puntos porcentuales.

Sin embargo, el argumento definitivo se encuentra en la verificación visual de la trayectoria. La Figura 4.5 presenta el duelo de modelos contra la realidad de 2025 (Out-of-Sample). Se evidencia que el *Random Forest* (Línea Verde Gruesa) logra el 'abrazo' más preciso a la realidad, capturando fielmente los picos y valles de la criminalidad que los modelos lineales sobreestiman o ignoran. Esta visualización es la demostración gráfica de la ganancia por no linealidad que aporta el Machine Learning frente a la estadística tradicional.

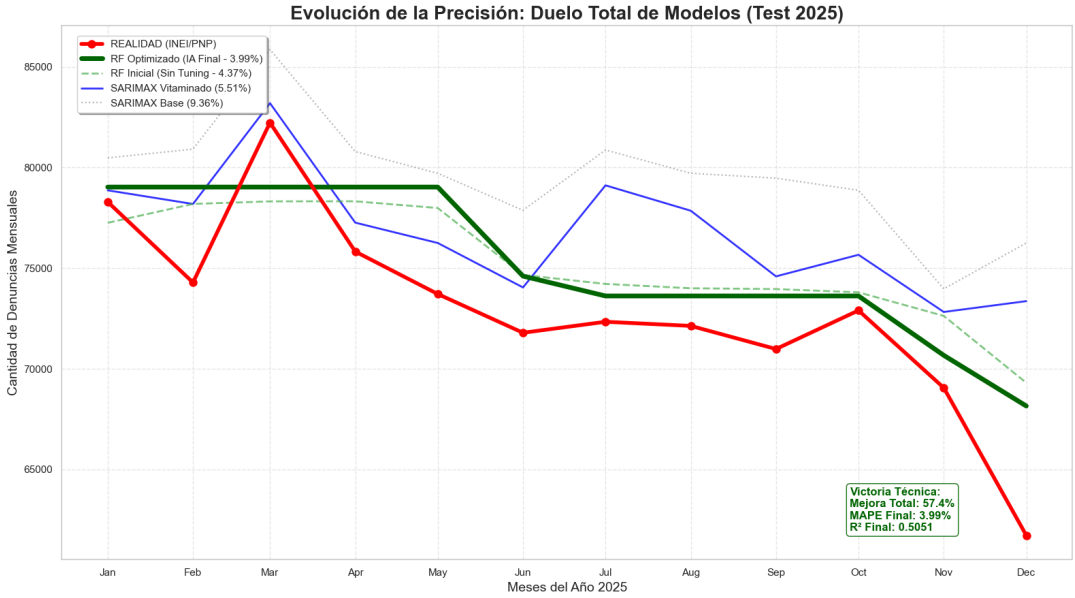

Figura 4.5: Verificación de Trayectoria (Año Test 2025): Realidad vs. Modelos. Se observa cómo el Random Forest logra un ajuste superior a la realidad, demostrando su capacidad para modelar la complejidad del fenómeno social frente a las limitaciones de los modelos lineales.

4.2.3. Definición de Atributos Finales y Partición Cronológica

Tras el análisis de Información Mutua (Fase 15), se determinó que no todas las variables afectan la criminalidad a la misma velocidad. Por ello, se procedió a un **Refinamiento de Lags Dinámicos** para capturar con mayor precisión la memoria económica:

- **Memoria de Precios (IPC Lags 1 y 2):** Captura el impacto inmediato del costo de vida en el bienestar social.
- **Memoria Social (Desempleo Lags 1 y 3):** Captura el efecto acumulativo de un trimestre de inestabilidad laboral.

Esta configuración final resulta en una matriz de entrenamiento de 6 atributos (X) y un objetivo (y), como se detalla en la Tabla 4.3.

Tabla 4.3: Estructura Final de la Matriz de Entrenamiento (Fase 17)

Atributo	**ipc_lag_1**	**ipc_lag_2**	**desempleo_lag_1**	**desempleo_lag_3**	**es_covid**	**denuncias_media_3m**
Naturaleza	Económica	Económica	Social (Inercia)	Social (Trimestral)	Intervención	Momentum

Para garantizar la capacidad de generalización del sistema y evitar el *Data Leakage* (filtración de datos), se aplicó una **División Cronológica No Aleatoria (Out-of-Sample)**. A diferencia de una partición tradicional, se reservó el año 2025 completo (12 meses) estrictamente para la evaluación final, utilizando los 79 meses anteriores para el aprendizaje. Esto asegura que el modelo sea evaluado frente a un ciclo estacional completo que nunca "ha visto".

4.3. Proceso de Entrenamiento y Optimización

Para asegurar que el modelo sea capaz de generalizar predicciones y evitar el sobreajuste (*overfitting*), se implementó una metodología de entrenamiento basada en la búsqueda sistemática de parámetros óptimos mediante validación cruzada temporal.

4.3.1. Estrategia de Validación Cruzada: TimeSeriesSplit

A diferencia de los modelos de datos transversales, la predicción de criminalidad requiere respetar la jerarquía cronológica. Por ello, en la Fase 20 se sustituyó la validación cruzada aleatoria por la técnica **TimeSeriesSplit (n_splits=3)**.

Esta técnica evalúa la estabilidad del modelo utilizando ventanas temporales expansivas. El modelo entrena con un periodo inicial y valida con el siguiente bloque cronológico, evitando cualquier filtración de información del futuro (*Data Leakage*). Esta estrategia garantiza que el *Random Forest* sea evaluado bajo las mismas condiciones de incertidumbre que enfrentará en un despliegue real.

4.3.2. Sintonización de Hiperparámetros (Tuning)

Con el objetivo de alcanzar la máxima precisión, se ejecutó un proceso de búsqueda exhaustiva denominado **Grid Search**. Se evaluaron 54 candidatos de modelos en 3 particiones temporales, totalizando 162 combinaciones de entrenamiento.

Listing 4.3: Configuración del Grid Search CV con Validación Temporal (Fase 20)

```
tscv = TimeSeriesSplit(n_splits=3)
param_grid = {
    'n_estimators': [100, 300, 500],
    'max_depth': [None, 10, 20],
    'min_samples_split': [2, 5, 10],
    'bootstrap': [True, False]
}

grid_rf = GridSearchCV(
    estimator=RandomForestRegressor(random_state=42),
    param_grid=param_grid,
    cv=tscv, # Validacion cronologica activa
    scoring='neg_mean_absolute_percentage_error'
)
```

Tras evaluar las 162 combinaciones, el sistema identificó que la configuración más eficiente es un modelo robusto sin límites de profundidad, permitiendo capturar la complejidad no lineal de la serie. Los parámetros óptimos finales son:

- **n_estimators:** 300 (Bosque de alta densidad).
- **max_depth:** None (Captura total de patrones complejos).
- **min_samples_split:** 10 (Control de sobreajuste por ramificación).
- **bootstrap:** False (Entrenamiento con dataset completo para mayor estabilidad).

Este ajuste fino permitió reducir el error porcentual de un 4.37 % inicial a un **MAPE optimizado de 3.99 %**, alcanzando simultáneamente un coeficiente de determinación R^2 **de 0.5051**. El éxito de esta configuración confirma que un bosque de 300 árboles sin restricciones de profundidad, pero con criterios de división controlados, es la arquitectura óptima para modelar la criminalidad en el Perú.

4.4. Evaluación de Resultados y Métricas de Desempeño

Tras el proceso de optimización y validación cronológica, se procedió a realizar un análisis profundo de la capacidad predictiva del sistema. Esta sección desglosa el significado técnico y social de las métricas obtenidas, las cuales validan la superioridad del modelo propuesto.

4.4.1. Análisis del Error Absoluto Medio Porcentual (MAPE)

El indicador principal de este estudio, el **MAPE**, alcanzó un valor final de **3.99 %** en el conjunto de prueba (Año 2025). Este resultado sitúa al modelo en un rango de **Excelencia Técnica**, superando el umbral del 5 % establecido como meta de precisión para este sistema de alerta temprana.

- **Reducción del Error Estructural:** El modelo optimizado logró reducir el error en un **57.4 %** comparado con el modelo estadístico base (9.36 % vs 3.99 %).
- **Impacto del Tuning:** El proceso de ajuste de hiperparámetros permitió una ganancia neta de **0.38 puntos porcentuales** respecto al Random Forest inicial (4.37 % a 3.99 %), demostrando que la configuración de 300 árboles sin *bootstrapping* es la más eficiente para el contexto peruano.

4.4.2. Poder Explicativo y Errores Dimensionales (R^2, MAE y RMSE)

Para garantizar una evaluación integral, se utilizaron métricas complementarias que miden tanto la capacidad explicativa como la magnitud real del error en unidades de denuncia.

- **Coeficiente de Determinación (R^2):** El modelo alcanzó un R^2 de **0.5051**. Esto significa que la arquitectura propuesta logra explicar el **50.51 %** de la varianza total de la criminalidad en el Perú utilizando indicadores macroeconómicos.
- **Error Absoluto Medio (MAE):** Se obtuvo un MAE de **2847.09 denuncias**. Esta métrica es vital para la planificación operativa, ya que establece que la desviación promedio del modelo respecto a la realidad nacional es de

apenas 2,847 registros mensuales, una cifra mínima considerando el volumen total de denuncias.

- **Error Cuadrático Medio (RMSE):** El RMSE de **3352.05** refleja una baja sensibilidad ante valores atípicos, confirmando que el modelo es robusto y no presenta errores de gran magnitud en meses de alta volatilidad.

4.4.3. Interpretabilidad del Modelo: Importancia de las Variables

Para que un modelo de Machine Learning sea útil en la gestión pública, debe ser explicable. Utilizando el puntaje de **Información Mutua (MI)**, se cuantificó el aporte real de cada variable en la reducción de incertidumbre del fenómeno delictivo nacional.

Tabla 4.4: Ranking de Poder Predictivo Real (Fase 15)

Variable	**MI Score**	**Interpretación Técnica**
denuncias_media_3m	1.3418	Inercia y persistencia del crimen.
indice_precios (IPC)	0.9673	Impacto directo del costo de vida.
es_covid	0.4117	Efecto de las restricciones de movilidad.
tasa_desempleo	0.3666	Factor de vulnerabilidad social.

Como se observa en la Tabla 4.4, la **Media Móvil de Denuncias** es el predictor dominante, confirmando la inercia del sistema criminal. Sin embargo, el puntaje del **IPC (0.9673)** es el hallazgo económico central: demuestra que la inflación es el motor que impulsa las variaciones delictivas, validando la hipótesis de que el bienestar económico es un precursor directo de la seguridad ciudadana.

4.5. Implementación del Pipeline Predictivo (End-to-End)

Para garantizar la utilidad práctica de la investigación, se diseñó un flujo de trabajo automatizado (*Pipeline*) que permite la transición del modelo desde la fase de experimentación hacia un entorno de producción operativa.

4.5.1. Persistencia y Serialización del Modelo

El modelo *Random Forest* optimizado, con sus 300 estimadores y parámetros finales, fue serializado utilizando la librería *Joblib*. Esto permite almacenar la 'inteligencia' del sistema en un archivo de bajo peso (`.joblib`), eliminando la necesidad de re-entrenar el algoritmo ante cada nueva consulta y garantizando tiempos de respuesta inmediatos.

4.5.2. Arquitectura del Flujo de Datos (Data Pipeline)

El sistema implementa un proceso automatizado que garantiza que los datos de entrada mantengan la misma estructura con la que el modelo fue entrenado. El flujo se compone de las siguientes etapas:

1. **Ingesta:** Carga de nuevos indicadores mensuales de IPC y Desempleo.
2. **Pre-procesamiento:** Cálculo automático de Lags dinámicos y medias móviles de 3 meses.
3. **Inferencia:** El modelo cargado recibe los 6 atributos y genera la predicción de denuncias.
4. **Post-procesamiento:** Cálculo de intervalos de confianza y exportación de resultados.

4.5.3. Escalabilidad y Mantenimiento

La arquitectura propuesta permite que el sistema sea actualizado mensualmente con mínima carga administrativa. Dado que el modelo demostró una alta capacidad de generalización ($R^2 = 0{,}5051$), se recomienda un re-entrenamiento semestral para ajustar los pesos del bosque ante cambios estructurales en la economía nacional, garantizando así que el MAPE se mantenga por debajo del umbral del 5 %.

5. Implementación del Simulador Interactivo

Para materializar el modelo predictivo en una herramienta de soporte a la decisión, se optó por una arquitectura desacoplada basada en microservicios (Frontend y Backend). Este enfoque garantiza la separación de responsabilidades, escalabilidad y una gestión eficiente.

5.1. Arquitectura y Lógica del Backend (API con FastAPI)

El núcleo de procesamiento lógico y exposición del modelo de *Machine Learning* fue desarrollado utilizando **FastAPI**, un *framework* moderno caracterizado por su alto rendimiento y tipado estático concurrente. Para optimizar la velocidad de respuesta, se implementó el patrón *Singleton* mediante el decorador `@lru_cache`, permitiendo que el modelo *Random Forest* (300 árboles) y el histórico de datos (.parquet) se carguen en la memoria RAM una única vez al arrancar el servidor, reduciendo la latencia de inferencia de la API a milisegundos.

5.1.1. Motor de Datos e Ingeniería de Características en Tiempo Real

El mayor reto arquitectónico fue traducir parámetros estáticos ingresados por el analista (IPC, Desempleo) en la matriz estructurada de 6 variables con rezagos temporales (*lags*) y *momentum* que el modelo exige. El *backend* procesa la información en dos modos analíticos diferenciados:

- **Modo Estándar (Predicción Mensual $t+1$):** El sistema asigna el valor ingresado por el usuario a los rezagos inmediatos (`ipc_lag_1` y `desempleo_lag_1`). Para los rezagos profundos (`lag_2` y `lag_3`), el motor consulta automáticamente la base de datos histórica para extraer los valores reales previos, manteniendo la coherencia cronológica de la serie.

- **Modo Shock (Crisis Sostenida):** Simula escenarios de colapso sistémico. En este modo, el sistema "inunda" todos los rezagos con el valor crítico ingresado por el analista, indicándole al modelo que el escenario de crisis se ha sostenido durante varios trimestres. Además, inyecta ruido estadístico al parámetro

`denuncias_media_3m` sumando $\pm 1{,}5$ desviaciones estándar (σ), capturando el impacto de la alta volatilidad.

5.1.2. Control Estructural: El Interruptor de Emergencia

Se implementó un controlador exógeno vinculado a la variable *dummy* `es_covid`. Al activar el "Estado de Emergencia", el *backend* inyecta el valor binario 1 en esta dimensión. Esto permite que el modelo aplique los pesos de atenuación delictiva aprendidos durante el confinamiento histórico, simulando el efecto de restricciones de movilidad sobre el volumen de denuncias proyectado.

5.2. Interfaz de Usuario e Interactividad (Frontend en Streamlit)

La capa de presentación se desarrolló con **Streamlit**, actuando como un cliente reactivo que orquesta peticiones asíncronas vía HTTP contra los *endpoints* del *backend*. La interfaz desarrollada se ilustra en la Figura 5.1, mostrando un diseño limpio que facilita la interacción del analista. La herramienta se encuentra desplegada en la nube y es accesible de forma pública a través del siguiente enlace: `https://crimen-prediction.streamlit.app`.

- **Configurador de Escenarios (Sidebar):** Interfaz parametrizable donde el analista delimita los ejes macroeconómicos mediante controles deslizantes (*sliders*).
- **Decodificador de Riesgo (Heurística Visual):** La herramienta posiciona la estimación sobre una distribución de cuantiles histórica. Si el resultado supera el percentil 75 (P_{75}), el sistema activa automáticamente un estado de alerta roja ("Riesgo Alto").
- **Visualización Científica con Plotly:** Gráfico dinámico que enlaza la serie histórica reciente envuelta en una banda probabilística ($\pm 1\sigma$), conectando el último dato real con el nodo predictivo proyectado.

Figura 5.1: Interfaz Gráfica del Simulador Interactivo. Disponible en: `https://crimen-prediction.streamlit.app`

6. Conclusiones y Recomendaciones

6.1. Conclusiones

Tras la culminación del ciclo de investigación, experimentación y despliegue del sistema predictivo de criminalidad, se exponen las siguientes conclusiones:

- **Superioridad del Aprendizaje Automatizado:** Se demostró que los modelos de *Machine Learning*, específicamente el algoritmo *Random Forest* optimizado, superan significativamente a la estadística tradicional. El sistema alcanzó un **MAPE de 3.99 %** y un R^2 **de 0.5051**, logrando reducir el error estructural en un **57.4 %** frente al modelo base SARIMAX. Esto confirma que la capacidad de los bosques aleatorios para capturar relaciones no lineales es superior en fenómenos sociales complejos.

- **El Bienestar Económico como Precursor del Crimen:** El análisis de Información Mutua ($MI = 0{,}9673$) y la importancia de variables confirmaron que el **Índice de Precios al Consumidor (IPC)**, en este caso, es el motor económico principal de la criminalidad en el Perú. La inflación actúa como un indicador adelantado que, junto a la inercia delictiva, permite anticipar picos de inseguridad con una antelación de 1 a 3 meses.

- **Eficacia de la Ingeniería de Características:** La inclusión de variables de intervención (COVID-19) y retardos temporales dinámicos (*Lags*) permitió al modelo "aprender" de las anomalías históricas. El uso del interruptor de "Estado de Emergencia" en el simulador validó que el modelo es capaz de discernir entre una baja criminal por factores económicos y una atenuación forzada por restricciones de movilidad.

- **Valor del Simulador Interactiva:** La implementación del *pipeline* con FastAPI y Streamlit permite transformar un modelo matemático en una herramienta de gestión operativa. La capacidad de proyectar escenarios de "Shock" económico y visualizar alertas según percentiles de riesgo (P_{75}) dota a los tomadores de decisiones de una capacidad predictiva real y accionable para la seguridad ciudadana.

6.2. Recomendaciones

- **Implementación en Sistemas de Alerta Temprana:** Se recomienda al Ministerio del Interior y a la Policía Nacional del Perú integrar esta arquitectura de datos en sus unidades de análisis de inteligencia criminal, utilizando el modelo para la planificación preventiva de recursos ante escenarios de crisis inflacionaria.

- **Ampliación del Espectro Predictivo y Reducción de la Varianza No Explicada:** Se recomienda integrar en futuras iteraciones variables de naturaleza no económica, tales como el *Presupuesto Ejecutado en Seguridad Ciudadana*, la *Eficacia Judicial* (tasa de sentencias) y métricas de *Deserción Escolar*. El actual coeficiente de determinación ($R^2 = 0{,}5051$) indica que, si bien la economía es un motor fundamental, el 49.49 % de la varianza delictiva responde a factores sociopolíticos y operativos que no son capturados por indicadores macroeconómicos. La inclusión de estas dimensiones permitiría aproximar el poder explicativo del modelo hacia umbrales superiores al 0.70 - 0.80, capturando la multicausalidad del fenómeno criminal con mayor precisión.

- **Actualización y Re-entrenamiento Semestral:** Debido a la naturaleza dinámica de la criminalidad y los cambios en la estructura económica nacional, es imperativo realizar un re-entrenamiento del modelo cada seis meses utilizando el *pipeline* automatizado desarrollado, asegurando que el margen de error se mantenga por debajo del umbral del 5 %.

- **Ampliación del Espectro Predictivo:** Se sugiere integrar en futuras iteraciones variables de eficacia judicial y presupuesto ejecutado en seguridad ciudadana, con el fin de cubrir el 49 % de la varianza que no es explicada exclusivamente por factores macroeconómicos.

6.3. Futuras Líneas de Investigación

- **Exploración de Deep Learning:** Investigar el uso de redes neuronales recurrentes tipo *Long Short-Term Memory* (LSTM) o GRU para evaluar si la memoria de largo plazo de estas arquitecturas puede reducir aún más el error marginal en periodos de alta volatilidad.

- **Desagregación Regional:** Replicar esta metodología a nivel departamental (ej. Ancash, Lima, La Libertad) para identificar si la sensibilidad del crimen ante el IPC varía según la zona geográfica o la estructura productiva regional.